TAREA M55 – CD-YAIR PALOMARES

```
import yfinance as yf
import pandas as pd
import warnings
warnings.filterwarnings('ignore')
```

```
IBM = yf.download(tickers='ibm', period = '5y', interval = '1d', rounding = True)
```

```
[*********************100%***********************]  1 of 1 completed
```

```
IBM
```

Price	Close	High	Low	Open	Volume
Ticker	IBM	IBM	IBM	IBM	IBM
Date					
2021-04-05	106.46	107.06	104.48	104.67	5722980
2021-04-06	105.12	106.23	105.02	106.19	3787566
2021-04-07	105.68	105.68	104.78	104.82	3112896
2021-04-08	105.83	106.23	105.07	105.40	4275211
2021-04-09	106.30	106.31	105.50	105.63	3162999
...	...	...	...	...	...
2026-03-26	241.67	246.67	239.80	240.56	3606800
2026-03-27	236.34	239.44	233.75	238.85	4853700
2026-03-30	237.25	240.21	236.13	237.80	3882600
2026-03-31	242.39	242.85	236.38	240.27	4747000
2026-04-01	243.14	246.26	240.14	242.12	2797144

1255 rows × 5 columns

```
walmart = yf.download(tickers='wmt', period = '5y', interval = '1d', rounding = True)
```

```
[*********************100%***********************]  1 of 1 completed
```

```
walmart
```

Price	Close	High	Low	Open	Volume
Ticker	WMT	WMT	WMT	WMT	WMT
Date					
2021-04-05	43.52	43.74	42.51	42.67	40043100
2021-04-06	43.72	43.99	43.23	43.42	31044600
2021-04-07	43.63	43.93	43.58	43.79	20361600
2021-04-08	43.60	44.04	43.59	43.83	19095600
2021-04-09	43.62	43.72	43.29	43.58	20676600
...	...	...	...	...	...
2026-03-26	122.18	123.80	121.79	123.61	16442500
2026-03-27	122.89	124.27	121.82	122.03	16543300
2026-03-30	123.50	125.26	123.14	123.71	20428900
2026-03-31	124.28	125.00	122.84	123.43	21322700
2026-04-01	124.74	125.23	123.13	124.00	16948532

1255 rows × 5 columns

```
IBM = IBM["Close"]
walmart = walmart["Close"]
```

```
import matplotlib.pyplot as plt

IBM['IBM'].plot()
walmart['WMT'].plot()
plt.legend(["IBM", "Walmart"])
plt.title("Comparación de precios IBM - Walmart")
plt.show()
```

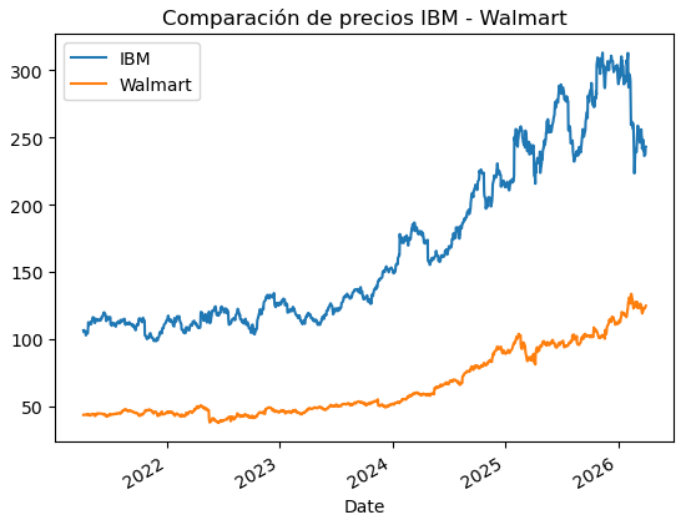


```python
# índice de correlación entre los precios de IBM - Walmart
correlacion = IBM["IBM"].corr(walmart["WMT"])
print("Correlación entre los precios de IBM y Walmart: ", correlacion)
```

```
Correlación entre los precios de IBM y Walmart:  0.9558632444713339
```

```python
import matplotlib.pyplot as plt
plt.scatter(IBM["IBM"], walmart["WMT"])
plt.show()
```

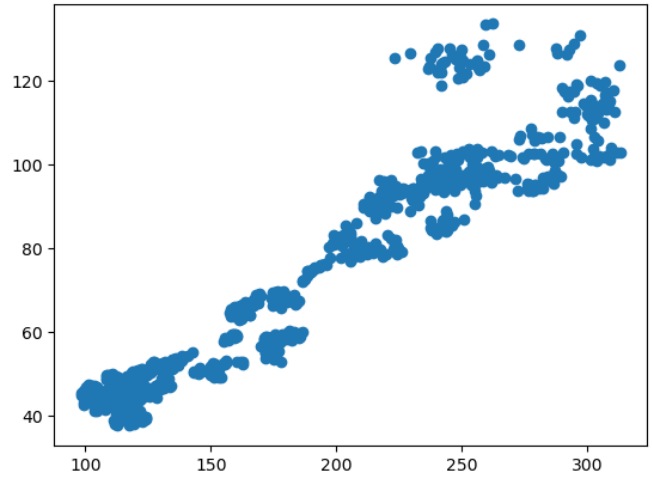

Conclusiones:

De acuerdo con el comportamiento de la gráfica de correlación y el valor estadístico obtenido, se deduce que los precios de la empresa IBM y Walmart si tienen relación. Esta relación es una tendencia positiva, es decir, cuando el precio de una compañía aumenta, el precio de la otra compañía también tiende a aumentar.

Descomposición de las gráficas de IBM y Walmart

```
IBM['IBM'].plot(label='IBM', figsize=(16,8))
walmart['WMT'].plot(label='Walmart')
plt.legend()
plt.grid()
plt.title("Comportamiento de precios")
plt.show()
```

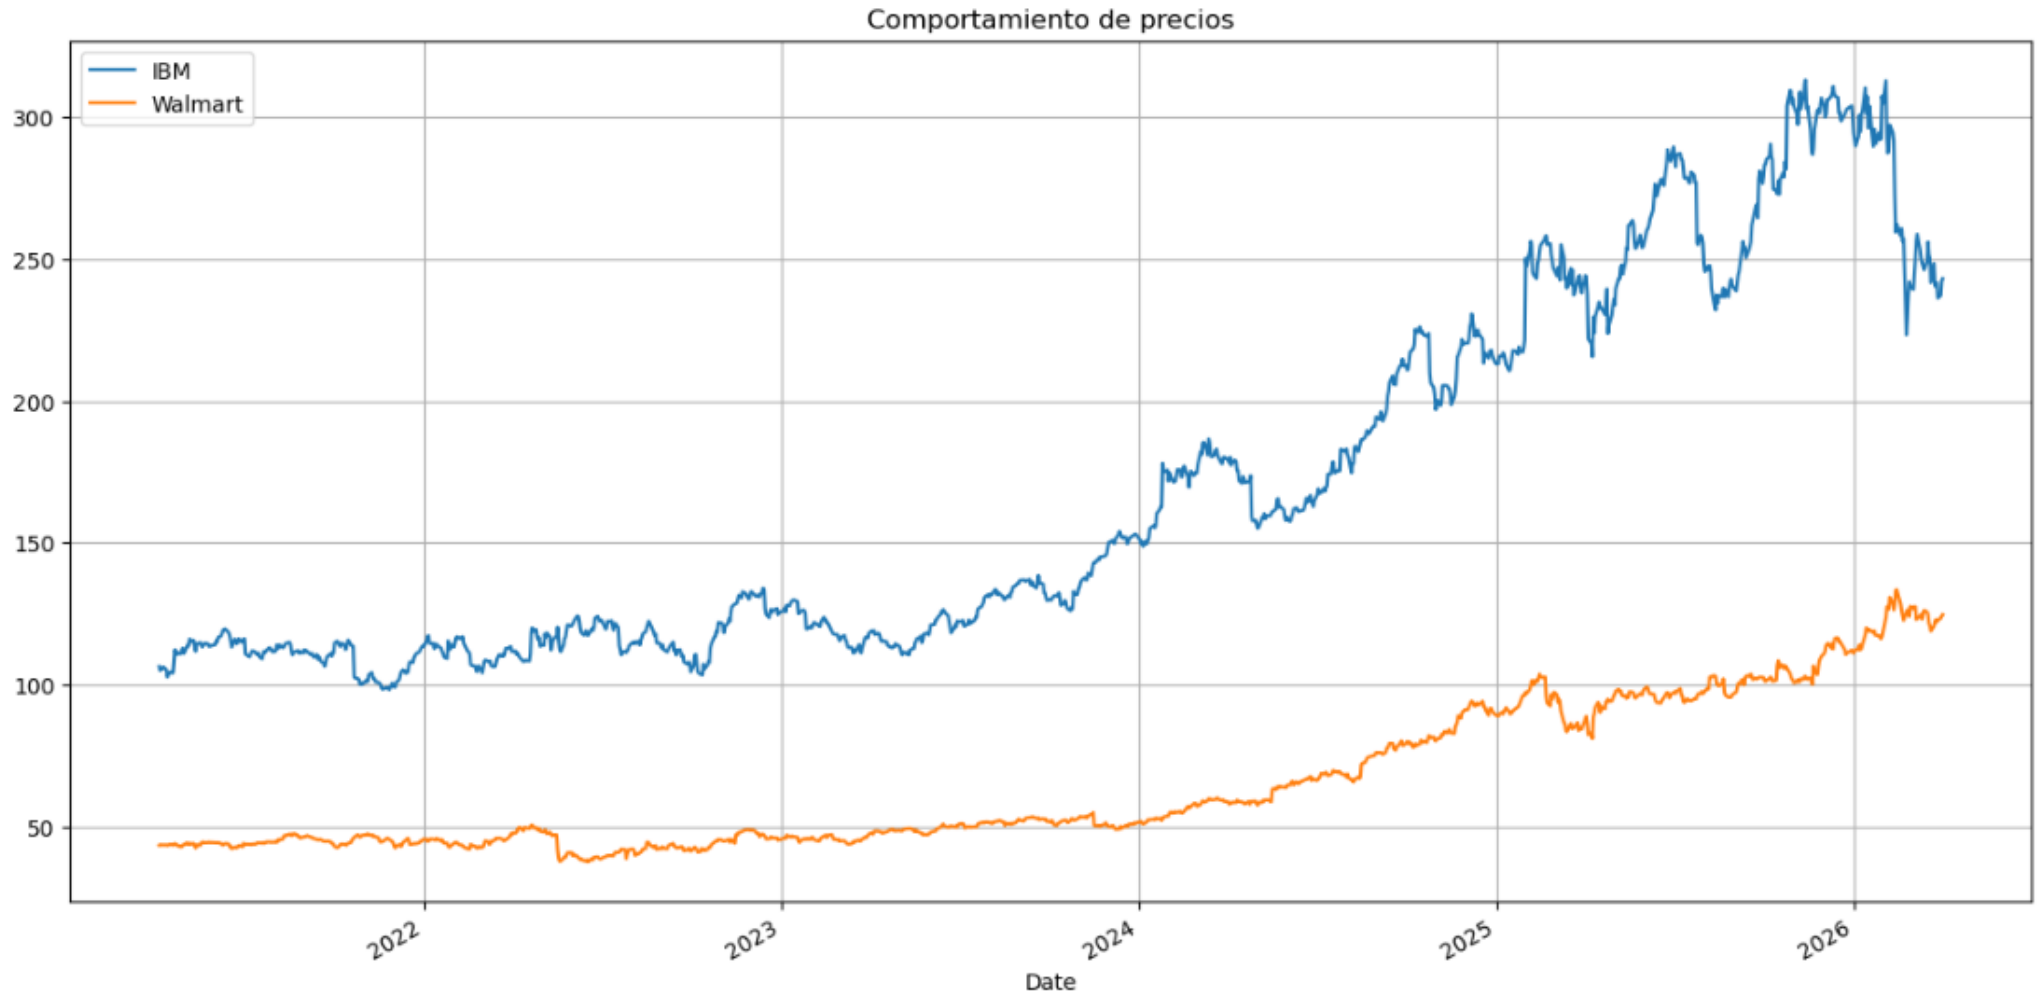

```python
#Descomposición de serie de tiempo para precios en IBM
decomposed_IBM = sm.tsa.seasonal_decompose(IBM, period=30)
figure = decomposed_IBM.plot()
plt.grid()
plt.show()
```

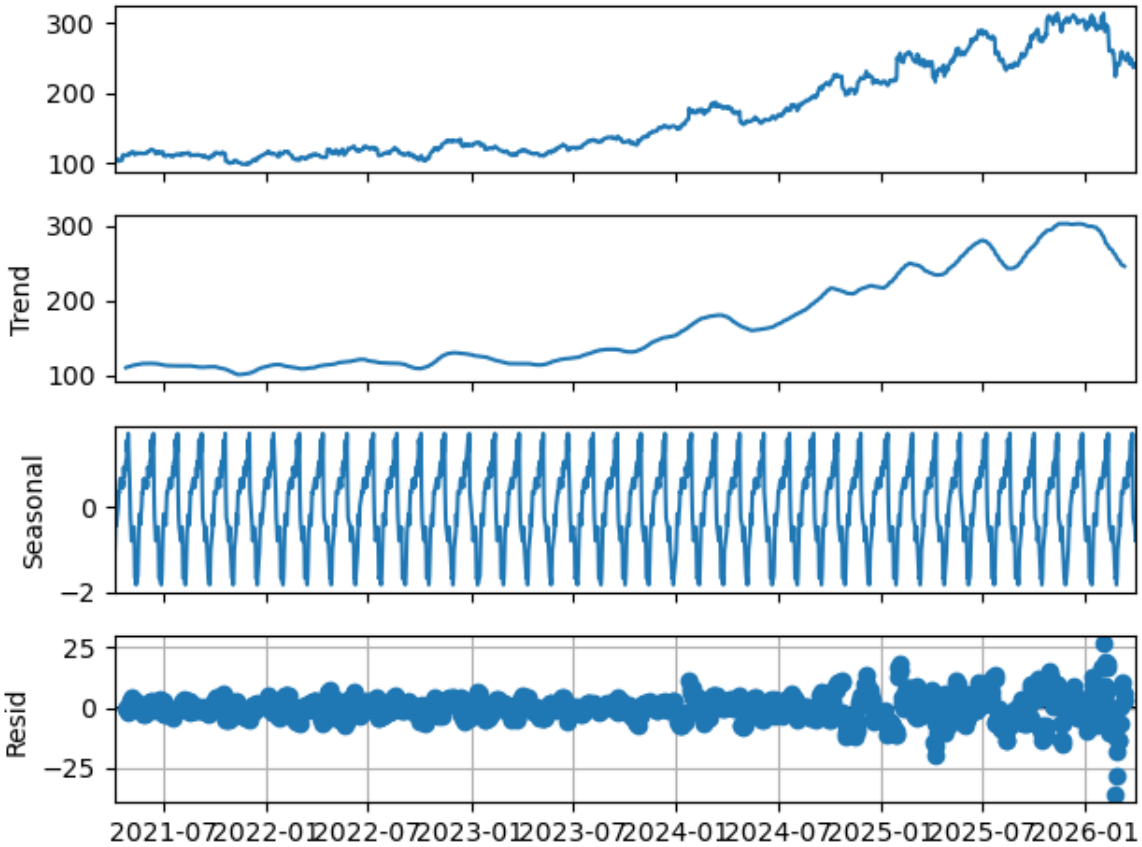

Conclusiones:

La tendencia del precio tiene un comportamiento al alta muy marcado, sobre todo después del 2024. Existe un patrón cíclico de estacionalidad, pero de acuerdo con la escala que representa, no influye de forma significativa en el resultado final, por lo que la tendencia domina sobre la estacionalidad.

Por otro lado, aproximadamente a partir de enero del 2025, el mercado se volvió mucho más volátil, ya que se observa mayor variabilidad que lo habitual.

```
#Descomposición de serie de tiempo para precios en Walmart
decomposed_WMT = sm.tsa.seasonal_decompose(walmart, period=30)
figure = decomposed_WMT.plot()
plt.grid()
plt.show()
```

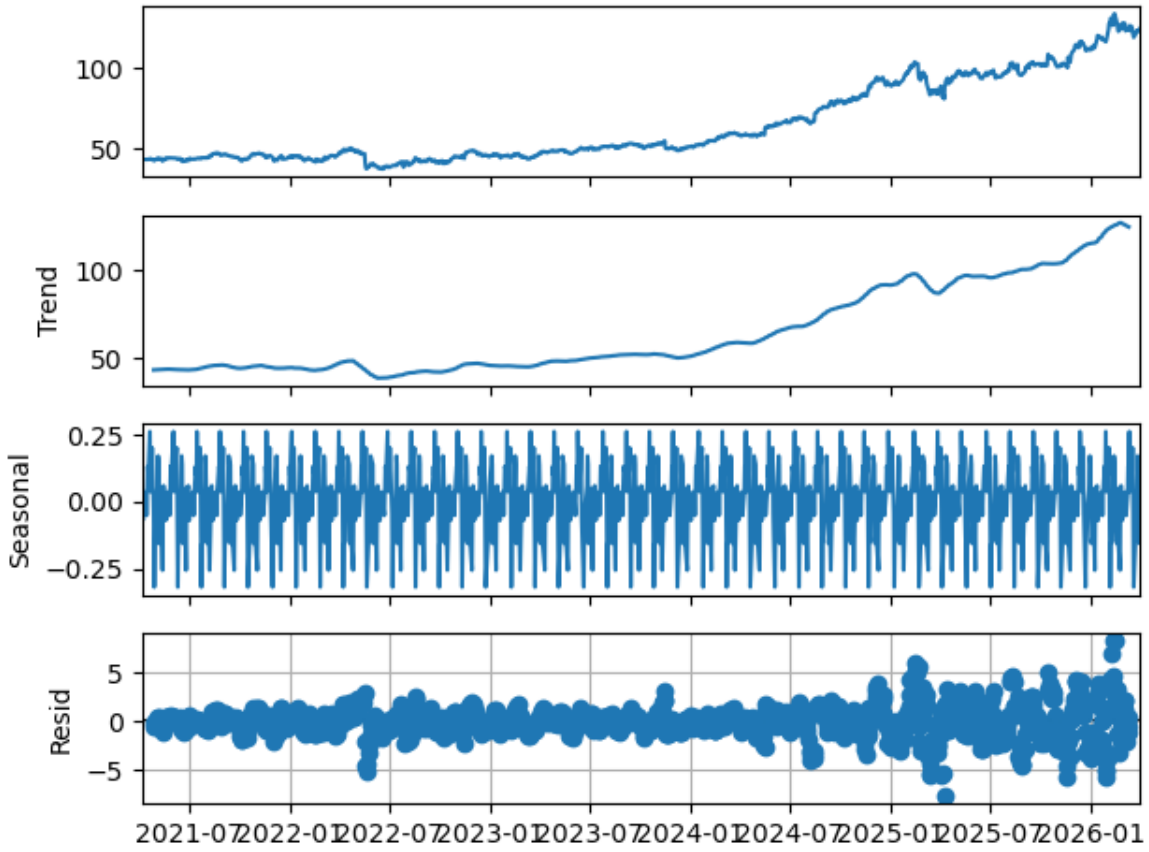

Conclusiones:

En lo que respecta al comportamiento del precio de Walmart, es bastante parecido a IBM. La tendencia positiva se observa más marcada a partir del 2024, y también existe estacionalidad, sin embargo, la escala de la estacionalidad es tan pequeña que no influye de forma significativa en el comportamiento final del precio.

Así mismo, la volatilidad del mercado ha aumentado considerablemente a partir del año 2025, ya que se puede observar mayor variabilidad de lo habitual.

Análisis de Autocorrelación

```
#Cálculo del índice de autocorrelación para IBM y Walmart
autocorrelacion_IBM = IBM["IBM"].autocorr()
print("El índice de autocorrelación para IBM utilizando intervalos de 1 día es: ", autocorrelacion_IBM)

autocorrelacion_WMT = walmart["WMT"].autocorr()
print("El índice de autocorrelación para Walmart utilizando intervalos de 1 día es: ", autocorrelacion_WMT)
```

```
El índice de autocorrelación para IBM utilizando intervalos de 1 día es:  0.9986918903289936
El índice de autocorrelación para Walmart utilizando intervalos de 1 día es:  0.9992479075743823
```

```
# Generación de la función de autocorrelación
from statsmodels.tsa.stattools import acf
from statsmodels.graphics.tsaplots import plot_acf
```

```
#Gráfica de autocorrelación para IBM
plot_acf(IBM, alpha = 0.05)
plt.title("Autocorrelograma para IBM")
plt.show()
```

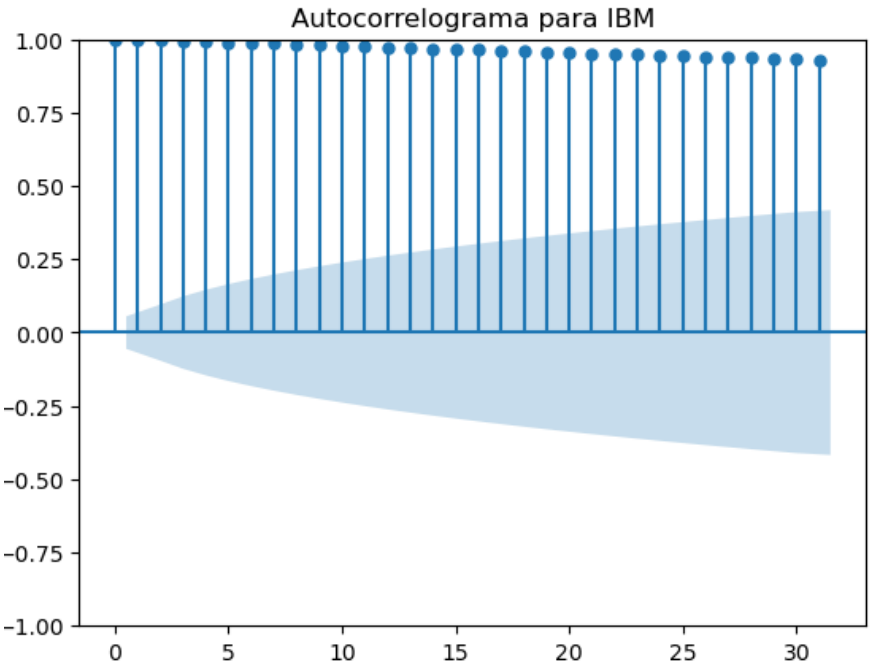

```python
#Gráfica de autocorrelación para Walmart
plot_acf(walmart, alpha = 0.05)
plt.title("Autocorrelograma para Walmart")
plt.show()
```

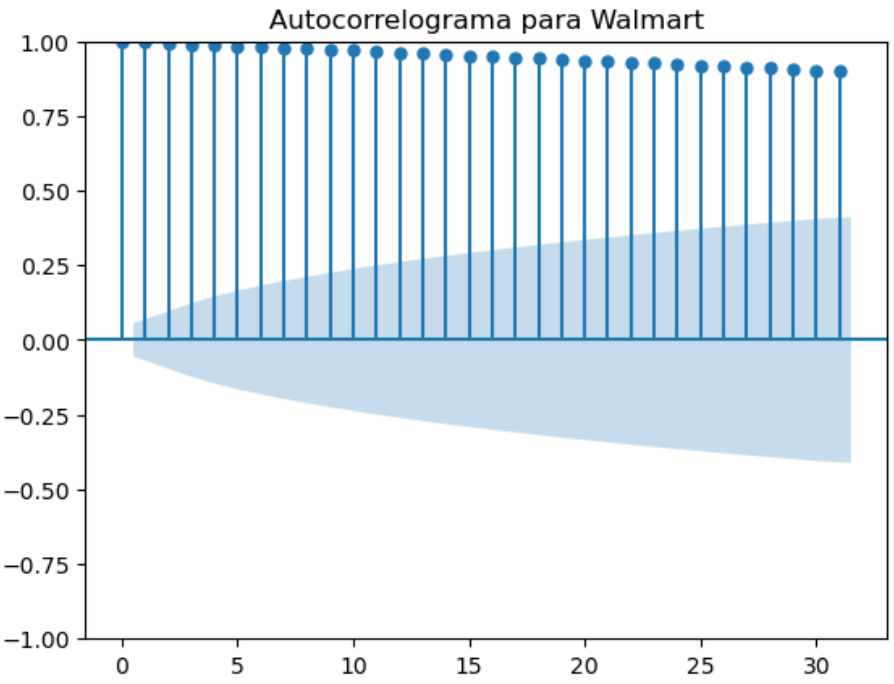

Conclusiones:

Para ambos casos es bastante claro que si existe autocorrelación en los precios de las compañías analizadas. Es decir, los precios están relacionados consigo mismo en los pasados lapsos de tiempo.

```python
#Prueba de Dickey-Fuller
from statsmodels.tsa.stattools import adfuller
import numpy as np

resultado = adfuller(IBM)
print("El valor p de la prueba para IBM es: " + str(resultado[1]))

resultado = adfuller(walmart)
print("El valor p de la prueba para Walmart es: " + str(resultado[1]))
```

```
El valor p de la prueba para IBM es: 0.8433651277014811
El valor p de la prueba para Walmart es: 0.9963338573302756
```

Conclusiones: Para ambas compañías, el valor p de la prueba de Dickey Fuller nos permite concluir que las series de tiempo no son estacionarias, es decir, los impactos o cambios en el precio tienen un efecto permanente.

Análisis gráfico de medias móviles

```
#Grupos de entrenamiento y prueba
len_train = int(IBM.shape[0] * 0.8)

train_IBM = IBM[0:len_train]
test_IBM = IBM[len_train:]
```

```
y_pred_IBM = IBM.copy()
y_pred_IBM = pd.DataFrame(y_pred_IBM)
y_pred_IBM["Pronostico"] = IBM.rolling(30).mean()
```

```
# La tabla se muestra desfasada, el promedio de los primeros 30 datos se utiliza la pronosticar la siguiente observación.
# Para solucionar este desfase hacemos lo siguiente:
y_pred_m_IBM = y_pred_IBM.copy()
y_pred_m_IBM.iloc[29,0] = np.nan
for contador in range(30,IBM.shape[0]):
    y_pred_m_IBM.iloc[contador,0] = y_pred_IBM.iloc[contador-1,0]
y_pred_m_IBM.tail()
```

Ticker	IBM	Pronostico
Date		
2026-03-26	241.39	248.151000
2026-03-27	241.67	247.378333
2026-03-30	236.34	246.540667
2026-03-31	237.25	246.010000
2026-04-01	242.39	245.421667

```
y_pred_m_IBM = pd.DataFrame(y_pred_m_IBM["Pronostico"][len_train:])

plt.figure(figsize = (20,5))
plt.grid()
plt.plot(train_IBM, label = "Train")
plt.plot(test_IBM, label = "Test")
plt.plot(y_pred_m_IBM["Pronostico"], label = "Prediction", color = "red")
plt.legend(loc = "best")
plt.title("Pronósticos mediante medias móviles para IBM")
plt.show()
```

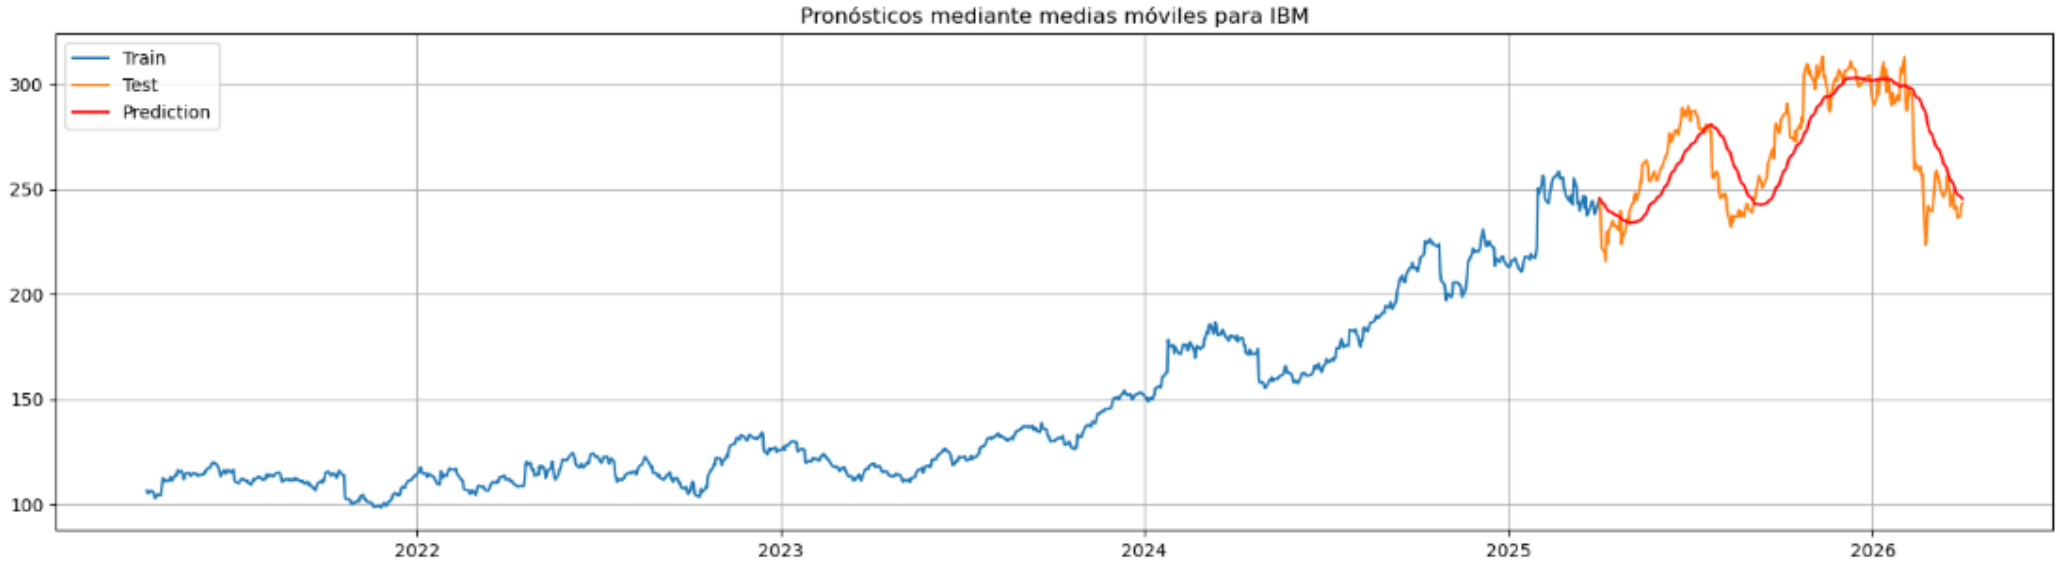


```
#Grupos de entrenamiento y prueba
len_train = int(walmart.shape[0] * 0.8)

train_WMT = walmart[0:len_train]
test_WMT = walmart[len_train:]

y_pred_WMT = walmart.copy()
y_pred_WMT = pd.DataFrame(y_pred_WMT)
y_pred_WMT["Pronostico"] = walmart.rolling(30).mean()

y_pred_m_WMT = y_pred_WMT.copy()
y_pred_m_WMT.iloc[29,0] = np.nan
for contador in range(30,walmart.shape[0]):
    y_pred_m_WMT.iloc[contador,0] = y_pred_WMT.iloc[contador-1,0]

y_pred_m_WMT = pd.DataFrame(y_pred_m_WMT["Pronostico"][len_train:])
```

```
plt.figure(figsize = (20,5))
plt.grid()
plt.plot(train_WMT, label = "Train")
plt.plot(test_WMT, label = "Test")
plt.plot(y_pred_m_WMT["Pronostico"], label = "Prediction", color = "red")
plt.legend(loc = "best")
plt.title("Pronósticos mediante medias móviles para Walmart")
plt.show()
```

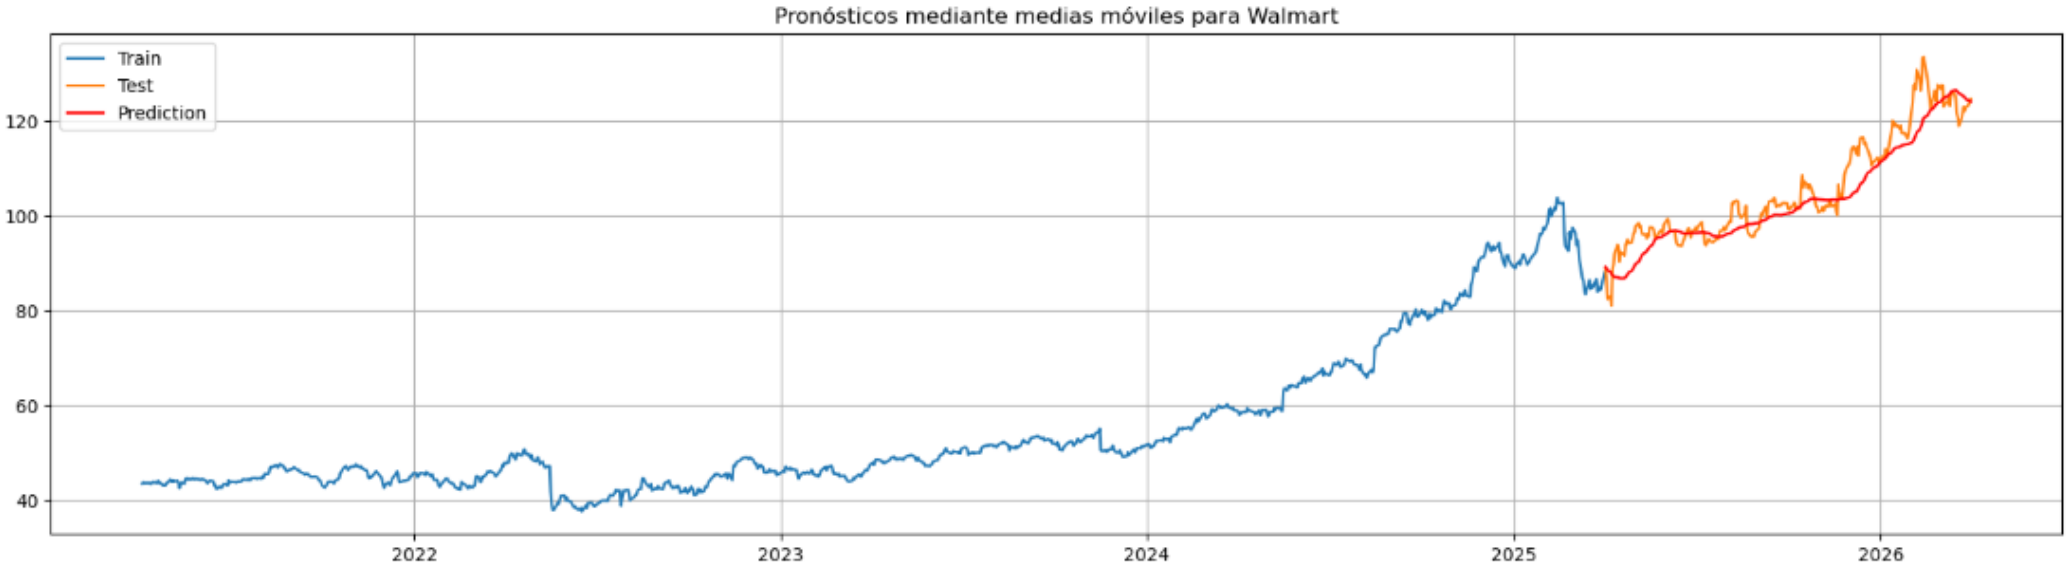


```python
#Pronóstico del día siguiente IBM
print("La predicción para el valor del precio en IBM del siguiente día es: ", y_pred_IBM.tail(1)["Pronostico"].iloc[0])
```

```
La predicción para el valor del precio en IBM del siguiente día es:  245.42166666666665
```

```python
#Pronóstico del día siguiente Walmart
print("La predicción para el valor del precio en Walmart del siguiente día es: ", y_pred_WMT.tail(1)["Pronostico"].iloc[0])
```

```
La predicción para el valor del precio en Walmart del siguiente día es:  124.14899999999999
```

```python
from sklearn.metrics import mean_squared_error

rmse_IBM = np.sqrt(mean_squared_error(test_IBM, y_pred_m_IBM)).round(2)
mape_IBM = np.round(np.mean(np.abs((test_IBM["IBM"] - y_pred_m_IBM["Pronostico"]) / test_IBM["IBM"])) * 100, 2)

rmse_WMT = np.sqrt(mean_squared_error(test_WMT, y_pred_m_WMT)).round(2)
mape_WMT = np.round(np.mean(np.abs((test_WMT["WMT"] - y_pred_m_WMT["Pronostico"]) / test_WMT["WMT"])) * 100, 2)
```

```python
print("El error en la predicción de IBM es:")
print("RMSE = ", rmse_IBM, "MAPE = ", mape_IBM)
print()
print("El error en la predicción de Walmart es:")
print("RMSE = ", rmse_WMT, "MAPE = ", mape_WMT)
```

```
El error en la predicción de IBM es:
RMSE =  17.07 MAPE =  5.18

El error en la predicción de Walmart es:
RMSE =  4.26 MAPE =  3.0
```

Conclusión:

Si espero que las predicciones realizadas sean buenas, ya que, de acuerdo a los indicadores de los errores de predicción, el error obtenido para IBM es de solo el 5.18%, y para Walmart del 3%. Por lo que el acercamiento es bastante bueno.